

**ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ**

**ΕΡΓΑΣΙΑ ΑΝΑΚΤΗΣΗΣ ΠΛΗΡΟΦΟΡΙΑΣ ΚΑΙ
ΑΝΑΖΗΤΗΣΗ ΣΤΟΝ ΠΑΓΚΟΣΜΙΟ ΙΣΤΟ
Υλοποίηση και Αξιολόγηση Συστήματος με Apache
Lucene**

**Ονοματεπώνυμο: Μπαρδάνης Αντώνιος
Αριθμός Μητρώου: Π21110**

1. Εισαγωγή

Σκοπός της παρούσας εργασίας είναι η εξοικείωση με τη βιβλιοθήκη **Apache Lucene** και η υλοποίηση ενός πλήρους συστήματος ανάκτησης πληροφορίας (Information Retrieval System). Το σύστημα οργανώνει μια συλλογή εγγράφων (CACM), δημιουργεί ευρετήριο και επιτρέπει την αναζήτηση με χρήση λέξεων-κλειδιών. Επιπλέον, πραγματοποιείται αξιολόγηση της απόδοσης του συστήματος συγκρίνοντας δύο διαφορετικά μοντέλα ανάκτησης: το Κλασικό Διανυσματικό Μοντέλο (Vector Space Model) και το Πιθανοτικό Μοντέλο Okapi BM25.

2. Υλοποίηση Συστήματος (Μέρος 1ο)

Η υλοποίηση βασίστηκε στην έκδοση **9.8.0** της βιβλιοθήκης Lucene και στη γλώσσα προγραμματισμού **Java**.

2.1. Προεπεξεργασία Κειμένου (Analyzer)

Για την ανάλυση των κειμένων δημιουργήθηκε η κλάση `MyAnalyzer`. Η διαδικασία περιλαμβάνει τα εξής στάδια:

- Tokenization:** Διαχωρισμός του κειμένου σε λέξεις (tokens).
- Lowercasing:** Μετατροπή όλων των χαρακτήρων σε πεζά.
- Stopwords Removal:** Αφαίρεση κοινών λέξεων (άρθρα, προθέσεις κ.λπ.) που δεν προσδίδουν σημασιολογική αξία, χρησιμοποιώντας τη λίστα από το αρχείο `common_words.txt`.
- Stemming:** Εφαρμογή του αλγόριθμου **Porter Stemmer** για την εξαγωγή της ρίζας των λέξεων (π.χ. η λέξη "computing" μετατρέπεται σε "comput"), βελτιώνοντας την ανάκληση του συστήματος.

2.2. Ευρετηρίαση (Indexing)

Η κλάση `Indexer` αναλαμβάνει την ανάγνωση της συλλογής κειμένων **CACM** (αρχείο `cacm.all`). Ο parser που υλοποιήθηκε διαβάζει το αρχείο γραμμή προς γραμμή και αναγνωρίζει τις ετικέτες:

- `.I:` Αναγνωριστικό εγγράφου (ID)
- `.T:` Τίτλος
- `.W:` Περιεχόμενο/Περίληψη (Abstract)
- `.A:` Συγγραφέας

Τα δεδομένα αποθηκεύονται σε πεδία (Fields) της Lucene, όπου το πεδίο του περιεχομένου ("content") ευρετηριάζεται πλήρως για αναζήτηση.


2.3. Αναζήτηση και Γραφικό Περιβάλλον

Δημιουργήθηκε εφαρμογή με γραφικό περιβάλλον (GUI) μέσω της κλάσης SearchApp (Java Swing). Ο χρήστης εισάγει το ερώτημα, το σύστημα εκτελεί την αναζήτηση και επιστρέφει τα αποτελέσματα ταξινομημένα κατά σχετικότητα (score).

Για κάθε αποτέλεσμα εμφανίζεται:

- Ο τίτλος και το ID του εγγράφου.
- Απόσπασμα κειμένου (Snippet) με **επισημασμένους τους όρους (Highlighting)** που βρέθηκαν, χρησιμοποιώντας την κλάση Highlighter της Lucene.

Στιγμιότυπα Εφαρμογής (Screenshots):



Εικόνα 1: Αποτελέσματα αναζήτησης για το ερώτημα "algorithm". Διακρίνεται ο τονισμός των λέξεων.

3. Αξιολόγηση Συστήματος (Μέρος 2ο)

Για την εκτίμηση της απόδοσης του συστήματος χρησιμοποιήθηκαν:

- Το αρχείο query.text που περιέχει 64 ερωτήσεις φυσικής γλώσσας.
- Το αρχείο qrels.text που περιέχει τις σωστές απαντήσεις (Relevance Judgments) για κάθε ερώτηση.

3.1. Μεθοδολογία

Υλοποιήθηκε η κλάση Evaluator, η οποία εκτελεί αυτόματα τις 64 ερωτήσεις και για κάθε μία υπολογίζει:

- **Precision (Ακρίβεια):** Το ποσοστό των ανακτηθέντων εγγράφων που είναι σχετικά.
- **Recall (Ανάκληση):** Το ποσοστό των σχετικών εγγράφων που ανακτήθηκαν.

Η διαδικασία εκτελέστηκε δύο φορές, μία για κάθε μοντέλο ομοιότητας:

1. **Classic Similarity (Vector Space Model):** Το παραδοσιακό μοντέλο TF-IDF.

--- Αποτελέσματα για Query ID: 1 ---											
Rank	DocID	Relevant?	Precision	Recall		Rank	DocID	Relevant?	Precision	Recall	
1	1938	false	0.0000	0.0000		28	1168	false	0.1071	0.6000	
2	1071	false	0.0000	0.0000		29	1885	false	0.1034	0.6000	
3	1410	true	0.3333	0.2000		30	637	false	0.1000	0.6000	
4	2371	false	0.2500	0.2000		31	2501	false	0.0968	0.6000	
5	1391	false	0.2000	0.2000		32	1591	false	0.0938	0.6000	
6	1440	false	0.1667	0.2000		33	1380	false	0.0909	0.6000	
7	2319	false	0.1429	0.2000		34	1487	false	0.0882	0.6000	
8	2535	false	0.1250	0.2000		35	1844	false	0.0857	0.6000	
9	3068	false	0.1111	0.2000		36	1471	false	0.0833	0.6000	
10	1590	false	0.1000	0.2000		37	1680	false	0.0811	0.6000	
11	1908	false	0.0909	0.2000		38	435	false	0.0789	0.6000	
12	1605	true	0.1667	0.4000		39	2218	false	0.0769	0.6000	
13	1033	false	0.1538	0.4000		40	1393	false	0.0750	0.6000	
14	1827	false	0.1429	0.4000		41	971	false	0.0732	0.6000	
15	2948	false	0.1333	0.4000		42	1304	false	0.0714	0.6000	
16	2372	false	0.1250	0.4000		43	3023	false	0.0698	0.6000	
17	2764	false	0.1176	0.4000		44	2950	false	0.0682	0.6000	
18	3025	false	0.1111	0.4000		45	2151	false	0.0667	0.6000	
19	1657	false	0.1053	0.4000		46	2379	false	0.0652	0.6000	
20	2632	false	0.1000	0.4000		47	1163	false	0.0638	0.6000	
21	1572	true	0.1429	0.6000		48	1570	false	0.0625	0.6000	
22	1682	false	0.1364	0.6000		49	1280	false	0.0612	0.6000	
23	1811	false	0.1304	0.6000		50	1542	false	0.0600	0.6000	
24	2126	false	0.1250	0.6000		-----					
25	2288	false	0.1200	0.6000		Mean Average Precision (MAP): 0.20849441550422634					
26	1247	false	0.1154	0.6000		=====					
27	1225	false	0.1111	0.6000							


2. **BM25 Similarity:** Το πιθανοτικό μοντέλο που αποτελεί την τρέχουσα βιομηχανική προεπιλογή.

--- Αποτελέσματα για Query ID: 1 ---											
Rank	DocID	Relevant?	Precision	Recall							
1	1410	true	1.0000	0.2000							
2	1938	false	0.5000	0.2000							
3	1391	false	0.3333	0.2000							
4	1590	false	0.2500	0.2000							
5	2535	false	0.2000	0.2000							
6	1908	false	0.1667	0.2000							
7	1071	false	0.1429	0.2000							
8	2319	false	0.1250	0.2000							
9	2371	false	0.1111	0.2000							
10	2572	false	0.1000	0.2000							
11	2372	false	0.0909	0.2000							
12	3025	false	0.0833	0.2000							
13	1572	true	0.1538	0.4000							
14	2632	false	0.1429	0.4000							
15	1605	true	0.2000	0.6000							
16	1827	false	0.1875	0.6000							
17	1440	false	0.1765	0.6000							
18	1487	false	0.1667	0.6000							
19	435	false	0.1579	0.6000							
20	2764	false	0.1500	0.6000							
21	1811	false	0.1429	0.6000							
22	1280	false	0.1364	0.6000							
23	1844	false	0.1304	0.6000							
24	1885	false	0.1250	0.6000							
25	1033	false	0.1200	0.6000							
26	2948	false	0.1154	0.6000							
27	2218	false	0.1111	0.6000							
28	2036	false	0.1071	0.6000							
29	637	false	0.1034	0.6000							
30	2201	false	0.1000	0.6000							
31	1854	false	0.0968	0.6000							
32	3068	false	0.0938	0.6000							
33	1225	false	0.0909	0.6000							
34	1570	false	0.0882	0.6000							
35	616	false	0.0857	0.6000							
36	397	false	0.0833	0.6000							
37	2501	false	0.0811	0.6000							
38	1247	false	0.0789	0.6000							
39	1412	false	0.0769	0.6000							
40	1680	false	0.0750	0.6000							
41	2288	false	0.0732	0.6000							
42	3011	false	0.0714	0.6000							
43	1542	false	0.0698	0.6000							
44	2704	false	0.0682	0.6000							
45	3069	false	0.0667	0.6000							
46	972	false	0.0652	0.6000							
47	2380	false	0.0638	0.6000							
48	3023	false	0.0625	0.6000							
49	1642	false	0.0612	0.6000							
50	2950	false	0.0600	0.6000							

Mean Average Precision (MAP): 0.22635018262426748											
Process finished with exit code 0											

3.2. Διαγράμματα Precision-Recall

Παρακάτω παρατίθεται το συγκριτικό διάγραμμα Ακρίβειας-Ανάκλησης για το ερώτημα ελέγχου.



Εικόνα 2: Συγκριτικό διάγραμμα Precision-Recall (Query ID: 1) για τα μοντέλα Vector Space και BM25.

3.3. Συμπεράσματα

Από την παρατήρηση του διαγράμματος και των γενικών αποτελεσμάτων (Mean Average Precision - MAP), προκύπτουν τα εξής συμπεράσματα:

1. **Φθίνουσα Πορεία:** Και στα δύο μοντέλα, καθώς αυξάνεται η Ανάκληση (Recall), η Ακρίβεια (Precision) μειώνεται. Αυτό είναι αναμενόμενο στα συστήματα ανάκτησης, καθώς για να βρούμε όλα τα σχετικά έγγραφα, αναγκαστικά ανακτούμε και περισσότερα άσχετα ("θόρυβο").
2. **Σύγκριση Μοντέλων:** Το μοντέλο **Okapi BM25** (πορτοκαλί γραμμή) εμφανίζει γενικά καλύτερη συμπεριφορά, ειδικά στα πρώτα αποτελέσματα (χαμηλό Recall), διατηρώντας υψηλότερη ακρίβεια σε σχέση με το Κλασικό Μοντέλο (μπλε γραμμή).
3. **Αιτιολόγηση:** Η υπεροχή του BM25 οφείλεται στον τρόπο που διαχειρίζεται τον κορεσμό της συχνότητας των όρων (term frequency saturation) και την κανονικοποίηση του μήκους των εγγράφων, αποφεύγοντας να δώσει υπερβολικό βάρος σε όρους που επαναλαμβάνονται πολλές φορές στο ίδιο κείμενο.